Techniques de Fouille des données

Niveau: **MP1 GL**

Fouille, Indexation et recherche de données

Niveau: **MP1 DS**

Introduction

Manel SEKMA
sekma.manel@gmail.com

AU 2025-2026
Niveau: **MP1 GL+DS**

Introduction: Evolution des sciences

- Avant 1600 : science empirique (expérimental)
- 1600-1950 : science théorique
- Années 50 - Années 90 : «Computational science»

- Depuis plus de 50 ans, beaucoup de disciplines se sont développées

- ***Simulation*** : trouver des modèles proches de la réalité

- 1990 - Aujourd'hui : «data science»

- Données omniprésentes

- capacité à gérer et stocker des volumes gigantesques.

- Internet

Solution: Data warehousing (exemples : Amazon Redshift, Google BigQuery, Oracle Exadata) et Data Mining sont devenus des challenges majeurs !

Data warehouse = stockage centralisé des données ;

Data mining = extraction de connaissances à partir de ces données.

The general data processing pipeline

INTRODUCTION

1. Business Understanding – Goals

- Information system inventory
- Data & information investigation
- Needs analysis and outputs
- Goals definition & action plan

Output: well-defined problem + measurable objectives

2. Data Understanding – Describe

- Data structure
- Variables
- Data types
- Data checking

Output: a clear view of what the data contains

3.Data Preparation – Analyze

3.1 Data Cleaning – Clean

- Missing values
- Duplicated values
- Inconsistent values

3.2 Data Analysis – Analyse

- Data visualization
- Data selection
- Data transformation
- Feature selection

Output: clean and relevant data

4. Data Modeling – Know

- Machine Learning
- Deep Learning
- AI Models

Knowledge Extraction !

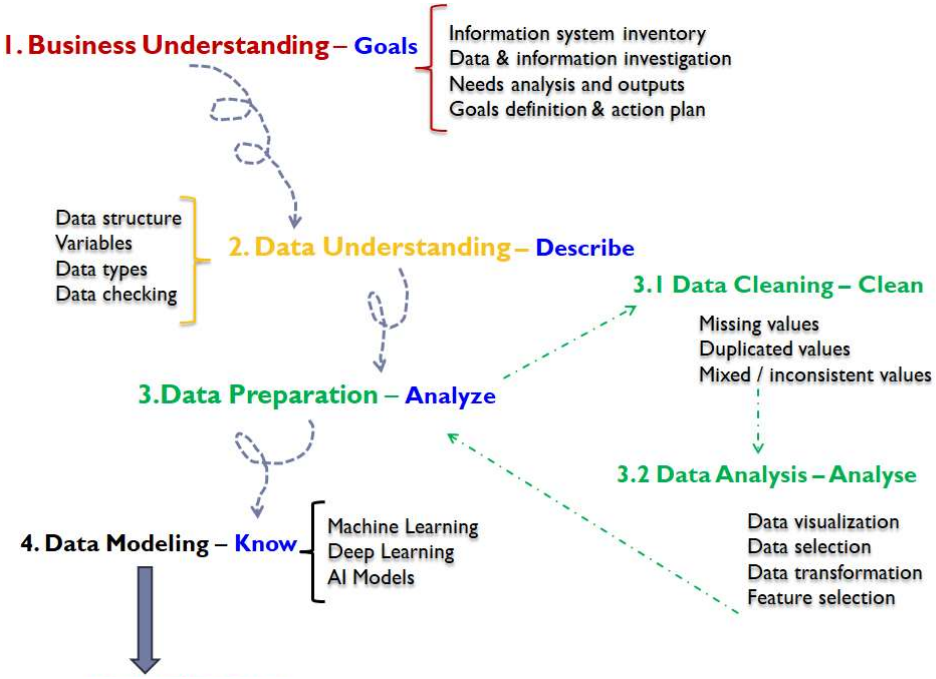

Knowledge Extraction !

5-Performance Evaluation – Check

Output: model validated or to be improved

Regression

RMSE,MAE, MSE

Classification

Recall, Precision, F1-score

Optimization (parameters tuning)

System integration
API
Application
Dashboard

6- Deployment – Produce

Fouille de Données

- Données ?
- Fouille ?

Pourquoi les données ?

Les données sont le carburant de la découverte et de l'innovation

- Sans données, vous êtes juste quelqu'un avec une opinion!
- Avoir des données signifie avoir une base solide et objective sur laquelle fonder les idées, arguments ou décisions.

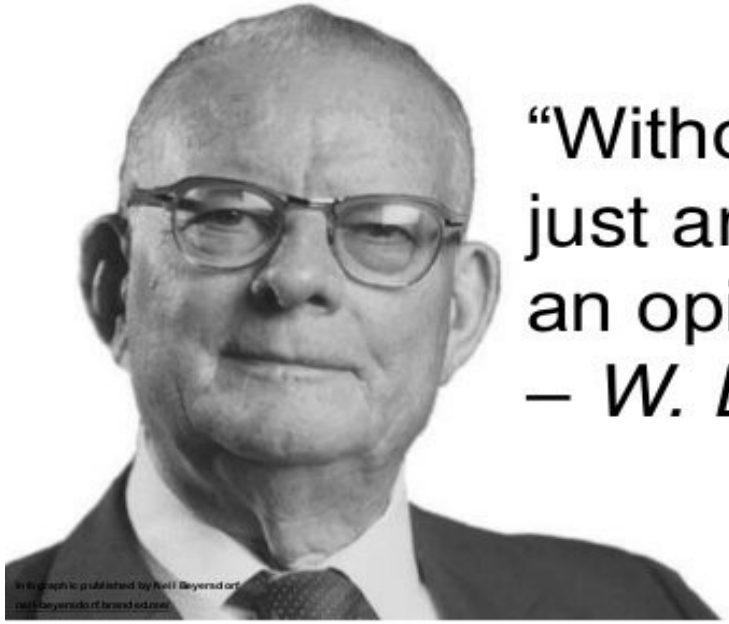

"Without data you're just another person with an opinion."
– *W. Edwards Deming*

William Edwards Deming (1900 – 1993): statisticien, qualiticien, professeur d'université, auteur et consultant américain.

Pourquoi Fouiller ?

- Comprendre les enjeux et les défis dans notre société et prendre des décisions stratégiques

  → Analyses pertinentes

Introduction

La fouille de données vise à découvrir, dans les **grandes quantités** de données,

- les informations précieuses qui peuvent aider **à comprendre** les données,
- ou à **prédire** le comportement des données futures.

Introduction

Fouille De Données (FDD) ou Data Mining (DM)

Le data-mining est un processus de découverte de règle, relations, corrélations et/ou dépendances à travers une grande quantité de données, grâce à des méthodes statistiques, mathématiques et de reconnaissances de formes.

Autres définitions :

- Un processus d'extractions automatique d'informations **prédictives** à partir de grandes bases de données.

Introduction

- **Data mining :**
  - Extraction d'informations intéressantes (implicites, et potentiellement utiles) à partir de grandes bases de données.

- **Le datamining est l'ensemble des:**
  - Algorithmes et méthodes
    - Destinés à l'exploration et l'analyse
    - De grandes quantités de données
    - En vue de détecter des règles, des tendances inconnues ou cachées, des structures particulières restituant de façon concise l'essentiel de l'information utile
    - … pour l'aide à la décision

Quelques définitions de la Fouille de Données

Pour un ensemble de données nommé D,
- le langage des faits L,
- la fonction d'intérêt $I_{D,L}$
- et le seuil **c**,

→ Trouver l'expression E telle que $I_{D,L}\ (E) > c$ efficacement

Analyse vs Fouille de données ?

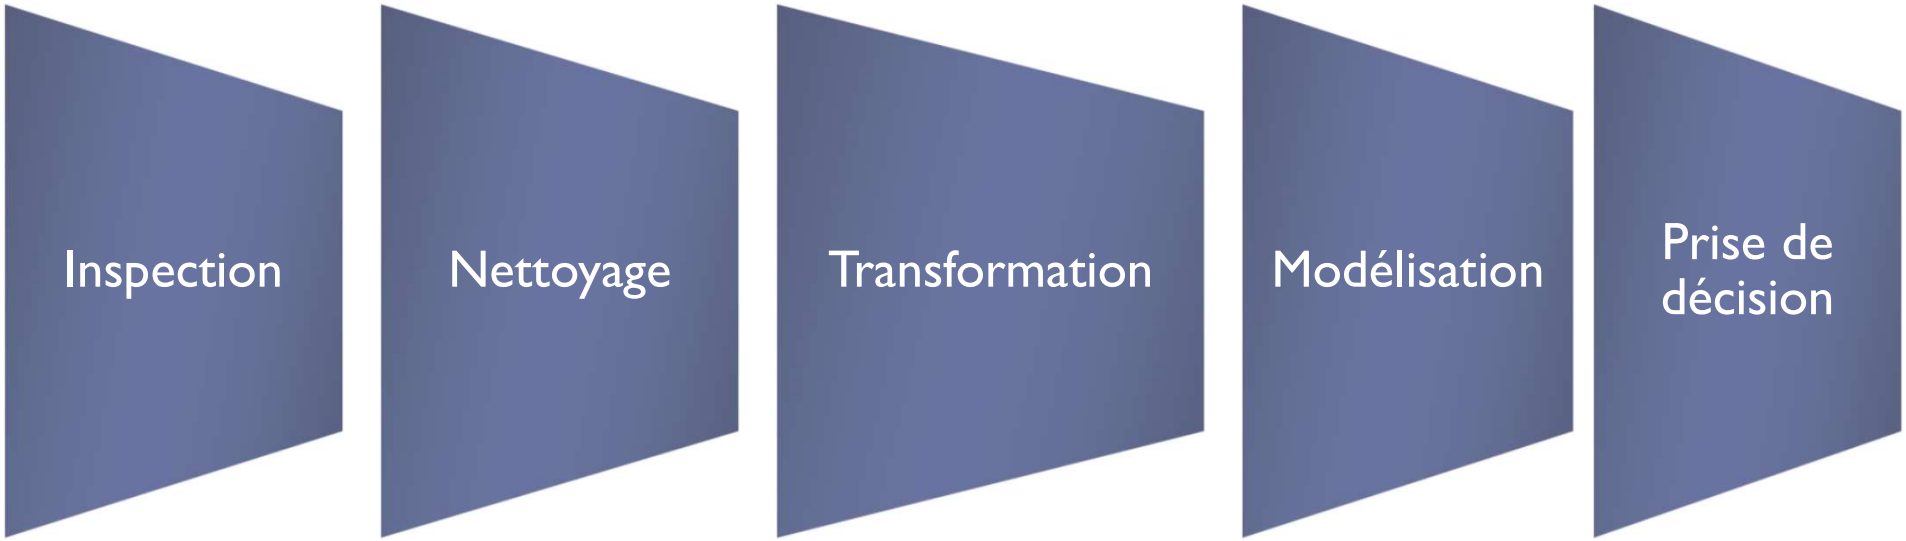

Phase du Processus de Données

Analyse de Données : Peut être effectuée à différentes étapes du processus, de l'exploration initiale des données à la validation des résultats.

Fouille de Données : Intervient généralement dans la phase de modélisation et d'exploration avancée après la préparation des données.

Analyse vs Fouille de données ?

- l'analyse de données vise à comprendre les données et à en tirer des informations utiles,

- la fouille de données se concentre spécifiquement sur l'identification de modèles complexes et de relations cachées dans des ensembles de données massifs.

- Les deux concepts sont complémentaires et font partie intégrante du processus d'exploration et d'utilisation des données pour prendre des décisions informées.

FDD: Sur quelles données ?

- Base de données relationnelles
- Base de données transactionnelles
- Base de données orientées objets
- Base de données relationnelles objets
- Base de données temporelles

FDD: Sur quelles données ?

- Base de données spatiales
- Base de données hétérogènes
- Base de données “héréditaires”
- Entrepôts de données
- Base de données textuelles
- Base de données multimédia
- Internet

→ Besoins de techniques particulières à chaque type de données pour la fouille de données

Traitement Base de données vs FDD

BD	**FDD**
Trouver les demandeurs de crédits ayant pour nom Salah.	Trouver les demandeurs de crédits ayant **un risque mineur** de remboursement
Identifier les clients ayant acheté plus de **500** dt le mois précèdent	Identifier les clients ayant **les habitudes d'achat similaires**
Trouver tous les clients qui ont acheté des livres	Trouver tous les objets qui sont **fréquemment acheté** avec les livres.

Traitement Base de données vs FDD

- Requête
  - Bien définie
  - SQL

Données
  - Données Opérationnelles

Sortie
  - Précise
  - Un sous-ensemble de la base de données

- Requête
  - Mal définie
  - Aucun langage de requête précis

Données
  - Données non opérationnelles

Sortie
  - Probable
  - Ce n'est pas un sous-ensemble de la base de données

Fonctionnalités du Data Mining

On distingue deux grandes familles de tâches réalisées en datamining

- **Description** : consiste à trouver les caractéristiques générales relatives aux données fouillées
- **Prédiction** : consiste à faire de l'inférence à partir des données actuelles pour prédire des évolutions futures

Fonctionnalités du Data Mining

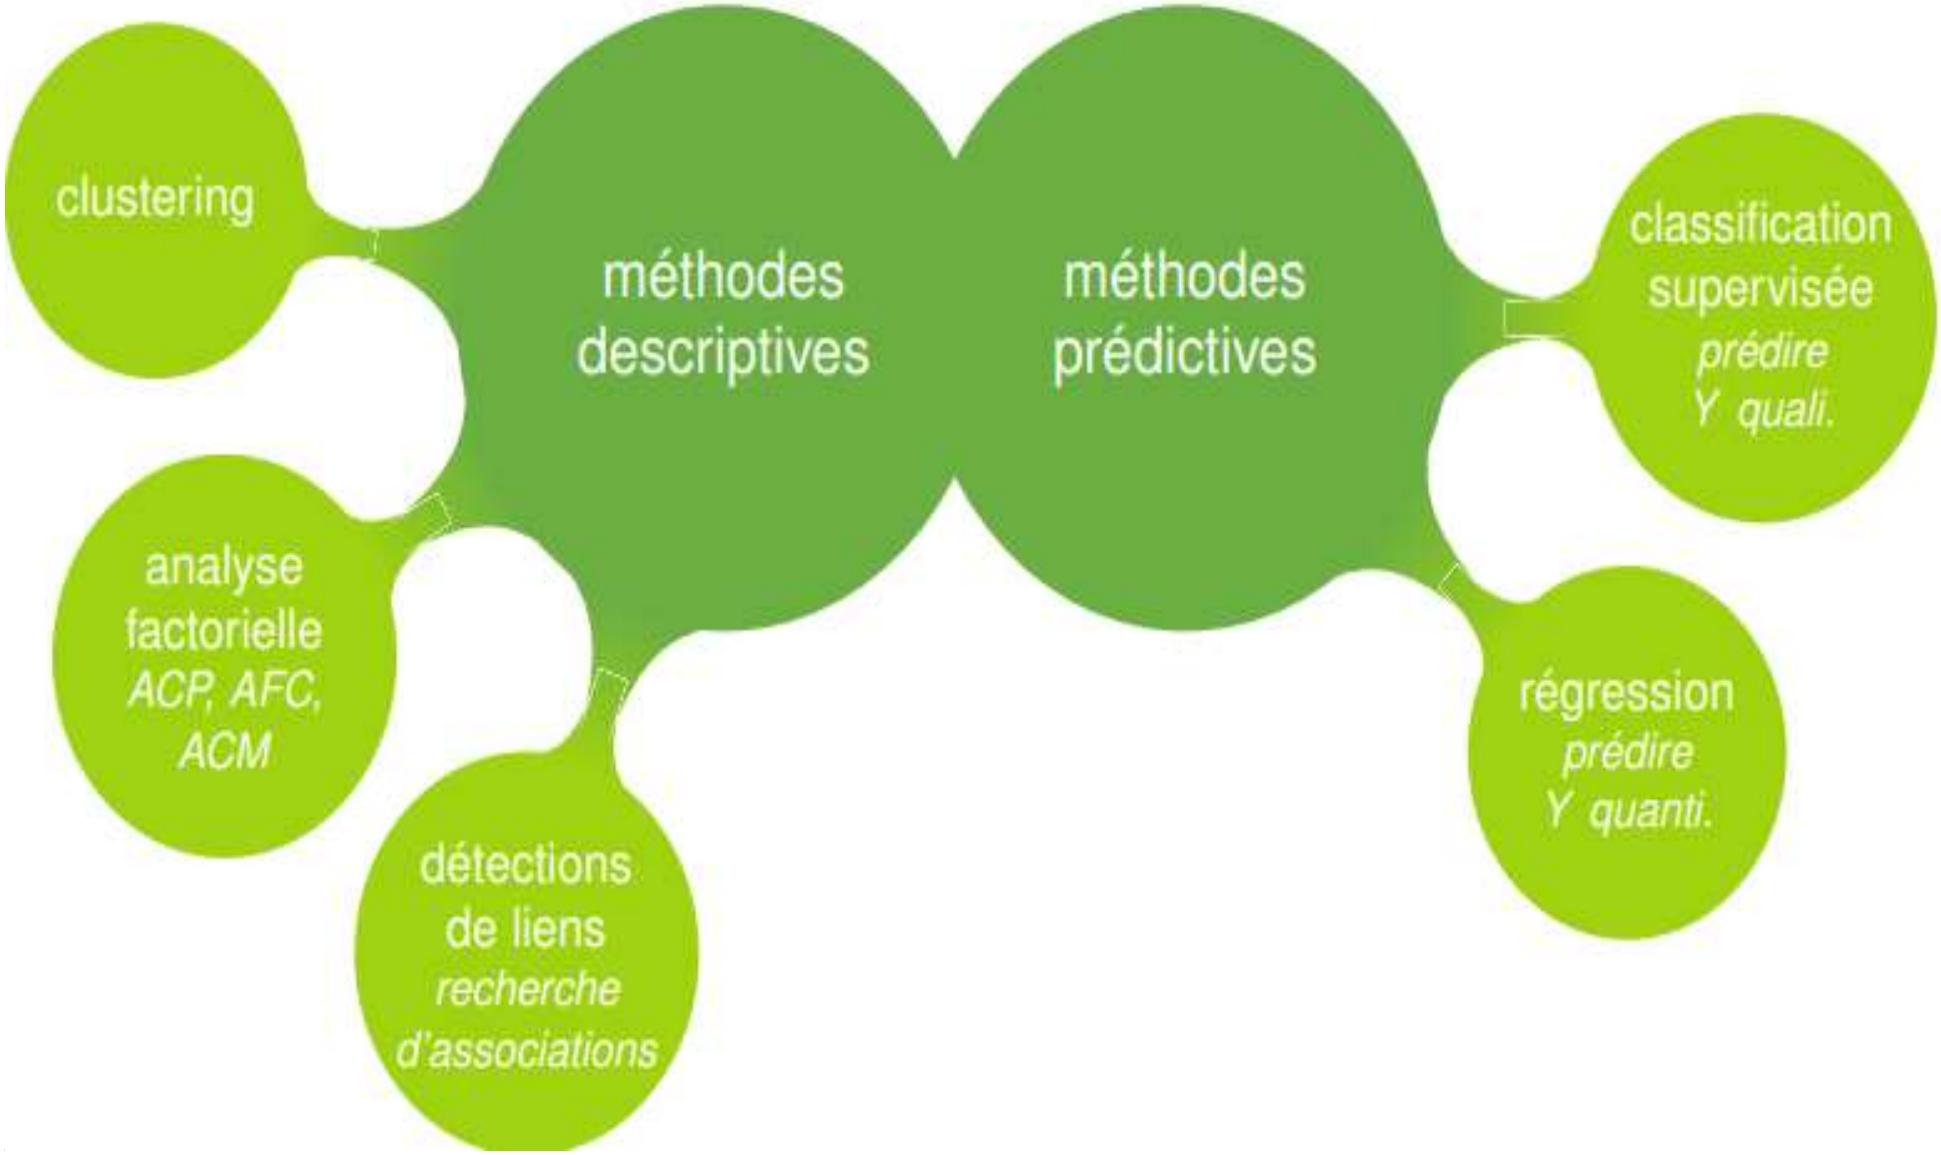

Fonctionnalités du Data Mining

Techniques descriptives

- Regroupement (ou segmentation, ou clustering)
- Recherche d'associations, de corrélations
- Recherche de séquences similaires

Fonctionnalités du Data Mining

Prédiction

- Vise à ***extrapoler de nouvelles informations*** à partir d'informations déjà présentes
- Il y a une variable cible à prédire

Fonctionnalités du Data Mining

Prédiction

Exemple : va-t-on faire du kite-surf ?

	TEMPS	HUMIDITE	VENT	kite-surf
Ex1	Soleil	Haute	Oui	Oui
Ex2	Soleil	Basse	Non	Non
Ex3	nuageux	Basse	Oui	Oui
Ex4	pluvieux	Haute	Oui	Non
Ex5	pluvieux	Basse	Oui	Non
Ex6	Soleil	Basse	Oui	Oui
Ex7	pluvieux	Basse	Non	Non
	Soleil	***haute***	***Non***	***?***

Va-t-on jouer s'il y a du soleil, beaucoup d'humidité et pas de vent ?

Fonctionnalités du Data Mining

Techniques prédictives

Classification

- Arbres de décision
- Classification bayésienne
- Réseaux neuronaux
- Méthodes SVM (support vector machine)
- Régression
- …

Fouille de données : déroulement non linéaire

Début

Extraire les données

Transformer les données

Fouiller les données

Valider les résultats

Tant que (résultats insuffisants ou information inexploitables) **faire**

Choisir une autre méthode de fouille

OU Revoir l'étape de transformation

OU Enrichir les données

Fouiller les données à nouveau

Valider les résultats

Fin Tant que

Terminer le projet

Fin

De la donnée à la connaissance : étude de cas

- Un supermarché vend 5 catégories de produits alimentaires :
  Produits laitiers – Boulangerie – Fruits & légumes – Viande & volaille – Boissons
- Il souhaite mieux étudier ses clients pour découvrir de nouveaux marchés où vendre plus de produits à ses clients habituels.

Q1 : Combien de clients ont acheté des produits laitiers cette année ?

Q2 : A-t-on vendu plus de produits laitiers cette année que l'année dernière ?

Q3 : Est-ce que les clients qui achètent des fruits et légumes achètent aussi des produits de boulangerie ?

Q4 : Quelles sont les caractéristiques principales des clients qui achètent souvent de la viande ?

Q5 : Peut-on prévoir quels clients vont arrêter d'acheter régulièrement et prendre des mesures pour les retenir ?

→ Questions de natures différentes mettant en jeu des processus différents

De la donnée à la connaissance : étude de cas

Q1 : Combien de clients ont acheté des produits laitiers cette année ?

- Réalisable en **SQL** à partir des données opérationnelles (tickets de caisse, table clients, table produits), sous réserve d'**indexations suffisantes** des tables concernées (date, catégorie produit, id client).
- Requête d'agrégation classique (**COUNT / GROUP BY**).
- Seule difficulté : ne pas pénaliser le **serveur transactionnel** par des requêtes trop longues → préférable d'interroger un **entrepôt de données (Data Warehouse)** ou une base répliquée pour l'analyse.

De la donnée à la connaissance : étude de cas

Q2 : A-t-on vendu plus de produits laitiers cette année que l'année dernière ?

- Réalisable en **SQL** avec des requêtes d'agrégation par année (SUM des ventes, COUNT des transactions).
- Nécessite un historique de données sur plusieurs années (dimension **temps** bien structurée).
- Peut impliquer des jointures importantes (ventes + produits + dates).
- Même contrainte de **Q1**

De la donnée à la connaissance : étude de cas

Q3 : Est-ce que les clients qui achètent des fruits et légumes achètent aussi des produits de boulangerie ?

- Non trivial en SQL simple : nécessite une analyse des **co-occurrences dans les paniers**.
- Question très ouverte → requiert une **règle d'association**

→ **C'est pour ce type de question que sont mis en œuvre des outils de fouille de données**

De la donnée à la connaissance : étude de cas

Q4 : Quelles sont les caractéristiques principales des clients qui achètent souvent de la viande ?

- Nécessite la construction d'un **profil client** (âge, fréquence d'achat, panier moyen, période d'achat…).
- Question très ouverte → requiert une **règle d'association**

→ C'est pour ce type de question que sont mis en œuvre des outils de fouille de données

De la donnée à la connaissance : étude de cas

Q5 : Peut-on prévoir quels clients vont arrêter d'acheter régulièrement et prendre des mesures pour les retenir ?

- Problème de **prédiction (classification)** basé sur l'historique des comportements clients.
- Processus plus complexe : sélection de variables, entraînement, validation du modèle.
- **Réalisé dans une plateforme data mining / ML, pas sur le système transactionnel.**

Data Mining : Un carrefour de connaissances

Typologies de la Fouille de Données

1. Typologie selon l'objectif
2. Typologie selon le type de modèle obtenu
3. Typologie selon le type d'apprentissage utilisé

Typologies de la Fouille de Données

1. Typologie selon l'objectif: classe les méthodes de fouille de données en fonction des **objectifs visés, soit:**

- **Classification** : examiner les caractéristiques d'un objet et lui attribuer une classe.
- **Prédiction** : prédire la valeur future d'un attribut en fonction d'autres attributs.
- **Association** : déterminer les attributs qui sont corrélés.
- **Segmentation** : former des groupes homogènes à l'intérieur d'une population.

Typologies de la Fouille de Données

2. Typologie selon le type de modèle obtenu:

Les méthodes sont regroupées selon le **type de modèle généré** :

- règles d'association,
- arbres de décision,
- modèles statistiques
- réseaux de neurones,

→ **chacun représentant la connaissance extraite de manière différente.**

Typologies de la Fouille de Données

3. Typologie selon le type d'apprentissage utilisé:

Cette typologie distingue les approches selon le mode d'apprentissage :

- supervisé (avec variable cible connue),
- non supervisé (détection de structures ou clusters)
- semi-supervisé,

→ **définissant la façon dont le modèle apprend à partir des données.**

Applications de la Fouille de Données

- Analyse de données et aide à la décision

  Analyse de marché

  - Marketing ciblé
  - Gestion des relations client
  - Analyse des achats des clients
  - Ventes croisées
  - Segmentation du marché

Applications de la Fouille de Données

Applications de la Fouille de Données

- Analyse de risque (Assurance)
- Grande distribution
- Médecine, Pharmacie
- Analyse financière
- Gestion de stocks
- Maintenance
- Contrôle de qualité

Applications de la Fouille de Données

- Autres Applications
  - Text mining : news groups, emails, documents Web.
  - Optimisation des requêtes
  - Reconnaissance d'images
  - Reconnaissance de textes
  - Reconnaissance du langage

Logiciels de la Fouille de Données

- Logiciels commerciaux :
  - Suites logicielles SAS (http://www.sas.com/offices/europe/france/)
  - SPSS d'IBM (http://www-01.ibm.com/software/fr/analytics/spss/)
  - Solution Analytics de SAP (http://www.sap.com/pc/analytics/strategy.html), KXEN
  - ...

Logiciels de la Fouille de Données

- Logiciels gratuits :

Weka :

• http://www.cs.waikato.ac.nz/ml/weka/

• Ensemble de classes et d'algorithmes JAVA developpés par l'Université de Waikato en

Nouvelle Zelande.

• Principaux algorithmes de data Mining.

• Utilisable en ligne de commande, à l'aide d'une

interface utilisateur, par l'API.

Logiciels de la Fouille de Données

- Logiciels gratuits :

TANAGRA :

• http://eric.univlyon2.
fr/~ricco/tanagra/fr/tanagra.html

• Destiné à l'enseignement et à la recherche.
Développé à l'Université de Lyon 2

• Principaux algorithmes de data mining.

– ORANGE :

• http://orange.biolab.si/

– ...

Références bibliographiques

- [1] Datamining : Concepts and techniques. J.Han & M. Kamber. Morgan Kaufmann 2000.

- [2] Introduction to Data Mining and its applications. S. Sumathi, S.N. Sivanandam. Springer Science & Business Media. 2006.

Techniques de Fouille des données

Chapitre 1: Découverte des règles d'association

Manel SEKMA
sekma.manel@gmail.com

AU 2025-2026
Niveau: **MP1 GL+DS**

Chapitre 2 : Découverte des règles d'association

Plan

1. Introduction
2. Problème
3. Préliminaires
4. Démarche de découverte/extraction des règles d'association
5. Algorithme Apriori
6. Code python

Introduction

- Le problème **d'extraction des règles d'association** fut introduit par **Agrawal** et al.
- Problème développé à l'origine pour l'analyse de bases de données de transactions de ventes.
- Il a pour but de découvrir des relations significatives entre les données de la base.
- **Applications** : rayonnage, mailing, cross marketing ...

Introduction

- Extraction des règles d'association :
  - Typologie des méthodes de la fouille de données selon les objectifs : **association**.
  - Typologie des méthodes de la fouille de données selon le type du modèle obtenu : **modèle descriptif**.
  - Typologie des méthodes de la fouille de données selon le type d'apprentissage : **apprentissage non supervise**.

Problème

- Etant donnée :

  – Une base de données de transactions de clients, ou chaque transaction est représentée par un ensemble d'articles **-set of items--**(ex., produits).

- Trouver :

  – Groupes d'articles (item set) achetés fréquemment (ensemble).

Exemple

- Analyse du panier de la ménagère.

Base de données de transactions
beurre, lait, pain
oeufs, farine, coca
....
couches, lait, ..

Exemple de base de données de transactions

Recherche de règles d'association ?.

Préliminaires

- Règles d'association
  - Motifs de la forme:

Prémisse/Antecédent → Conclusion/Conséquent [support, confiance]

- Support et confiance sont des mesures d'intérêt définies par l'utilisateur.

Préliminaires

- Règles d'association

Soit X et Y deux produits;

- Interprétation R : XY (A%, B%)
- **A%** de toutes les transactions montrent que X et Y ont été achetés en même temps (Support de la règle).
- Support P(X⇒Y) = P(X et Y)

- **B%** des clients qui ont acheté X ont aussi acheté Y (confiance dans la règle).
- Confiance P(X⇒Y) = P(Y | X) = P(X et Y)/P(X)

Préliminaires

- Exemples des règles d'association :
  - Achat (x, « Beurre ») ET Achat (x, « Pain ») → Achat(x, « Lait ») [70%, 80%]
  - « Introduction à Unix » ⇒« Programmation C » [34%, 84 %]

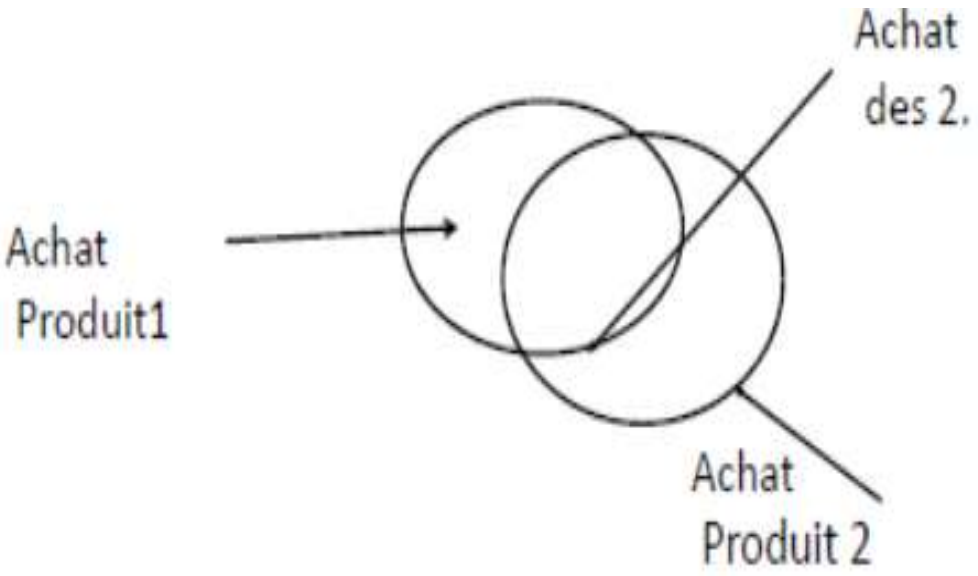

Préliminaires

- Exemples des types des règles d'association :

  – **Règle booléenne :**
  - achète(x,"SQLServer") ^ achète(x,"DMBook") ⇒ achète(x, "DBMiner") [0.2%, 60%]

  – **Règle quantitative :**
  - âge(x,"30..39") ^ salaire(x,"42..48K") ⇒ achète(x,"PC") [1%, 75%]

Préliminaires

- Soit $I = \{i_1, i_2, \ldots, i_n\}$ un ensemble de littéraux appelés **items**.
- Un itemset **X** : un ensemble d'items $X \subseteq I$
- Une base de données *D* consiste en un ensemble de transactions T_i t.q. $T_i \subseteq I$
- On dit que T contient X si $X \subseteq T$.
- Une transaction n'a pas de duplicats.

Préliminaires

- Soit une base de données D
  - un ensemble de n transactions
  - chaque transaction est nommée par un identifiant (TID).
- Les items d'une transaction ou d'un itemset sont triés suivant un ordre lexigographique.

Préliminaires

- Longueur d'un itemset = nombre d'items qu'il contient.
- k-itemset : itemset de longueur k.
- Un ensemble d'items (itemset) X de cardinalité k = |X| est appelé un **k-itemset.**
  - 3-itemset : {Café, Moutarde, Saucisse}

Préliminaires -- Exemple

- I = { Café, Couche, Gâteaux,Moutarde,Saucisse...}
- T1 = {Café,Moutarde,Saucisse}
- D = {{T1, {Café,Moutarde,Saucisse}},

  {T2, {Café, Fromage, Gâteaux}}, ...}

Préliminaires -- Exemple

Client	Pizza	Lait	Sucre	Pommes	Café
1	1	0	0	0	0
2	0	1	1	0	0
3	1	0	0	1	1
4	0	1	0	0	1
5	1	0	1	1	1

Figure 1 : Représentation de la base de données

Métriques d'évaluation

- Lors de l'analyse des règles d'association dans un ensemble de données, plusieurs métriques sont utilisées pour évaluer la fréquence, la force et la pertinence des relations identifiées→ pertinence des règles

Métriques d'évaluation (Pertinence des règles)

- **Support (relatif) :**
  - **Information :** Mesure la fréquence relative d'un ensemble d'éléments dans l'ensemble de données.
  - **Objectif :** Identifier les ensembles d'éléments fréquents.
- **Confiance :**
  - **Information :** Mesure la probabilité conditionnelle que la présence d'un ensemble d'éléments entraîne la présence d'un autre ensemble.
  - **Objectif :** Évaluer la force de la relation entre les ensembles d'éléments.
- **Lift :**
  - **Information :** Mesure la force de l'association entre deux ensembles par rapport à ce qui pourrait être attendu au hasard.
  - **Objectif :** Évaluer la pertinence de l'association, indiquant si elle est significative par rapport à un scénario aléatoire.

Métriques d'évaluation (Pertinence des règles)

Règle: X => Y

Support (relatif) = $\frac{frq(X,Y)}{N}$

Confidence = $\frac{frq(X,Y)}{frq(X)}$

Lift = $\frac{support}{supp(X) \times supp(Y)}$ vraisemblance

$= \frac{P(X \cap Y)}{P(X) \times P(Y)}$

Lift

- *Si Lift = 1, savoir que A est présent ne change rien pour B." "Si Lift = 2, B est 2 fois plus probable quand A est présent.*
- On élimine souvent les règles avec : $\boxed{Lift \leq 1}$

Exemple d'Interprétation pratique

Lift	**Interprétation pratique**
≈ 1 (0.95 – 1.05)	Considéré comme **hasard / non intéressant**
> 1.1	Association faible mais réelle
> 1.3 – 1.5	Association modérée, souvent intéressante
> 2	Association forte (rare mais très informative)

Exemple1 simple

A l'instant, on regarde l'état des paniers à chariot dans un supermarché:

Questions:

1- Quel est le nombre des transactions dans ce supermarché à cet instant?

2-Quel est le nombre des articles achetés dans ce supermarché?

Exemple1 simple-correction

Support (relatif) = $\frac{frq(X,Y)}{N}$

Soit la régle d'association suivante:

A => D

Confidence = $\frac{frq(X,Y)}{frq(X)}$

Lift = $\frac{support}{supp(X) \times supp(Y)} = \frac{P(X \cap Y)}{P(X) \times P(Y)}$

En logique mathématique, on dit A implique D (on dit aussi : si A alors D)

En Retail Busniess: si le client achète l'article A alors il va acheter l'article D

Question: Calculer le support, la confiance et le lift de cette règle.

Exemple1 simple-correction

$$\text{Support (relatif)} = \frac{frq(X,Y)}{N}$$

$$\text{Confidence} = \frac{frq(X,Y)}{frq(X)}$$

$$\text{Lift} = \frac{\text{support}}{supp(X) \times supp(Y)} = \frac{P(X \cap Y)}{P(X) \times P(Y)}$$

Pour la règle d'association **A => D**

frq(A,D): on calcul le nombre d'articles où on trouve A et D au même moment.

- Calcul du support : frq(A,D)=2 et N=5 alors le support =2/5

- Calcul de la confiance: frq(A)=3 et frq(A,D)=2 alors la confiance =2/3

- Calcul du lift: supp(A)=3/5, supp(D)=3/5, support =2/5 alors = $\frac{(2/5)}{((3/5)\times(3/5))}$ = 10/9

Exemple1 simple-correction

$$\text{Support (relatif)} = \frac{frq(X,Y)}{N}$$

$$\text{Confidence} = \frac{frq(X,Y)}{frq(X)}$$

$$\text{Lift} = \frac{\text{support}}{supp(X) \times supp(Y)} = \frac{P(X \cap Y)}{P(X) \times P(Y)}$$

Rule	Support	Confidence	Lift
A=>D	2/5	2/3	10/9
C=>A	2/5	2/4	5/6
A=>C	2/5	2/3	5/6
B&C=>D	1/5	1/3	5/9

Exemple 2 simple

- Supposons qu'il y ait 100 clients (transactions) 10 d'entre eux ont acheté du lait, 8 ont acheté du beurre et 6 ont acheté les deux.

Règle: Lait acheté => beurre acheté

- Support=?
- Confidence=?
- Lift=?

Supp relat=fre(lait, beurre)/100=6/100=0,06
Confid=freq(lait,beurre)/freq(lait)=6/10
Lift= supprelat=0,06/(suppp(lait)=10/100
supp(beurre)=8/100)= 7,5

Démarche de découverte/extraction des règles d'association

- Paramètres :
  - Fixer un degré d'exigence sur les règles à extraire :
    - Support min
    - Confiance min

Démarche de découverte/extraction des règles d'association

1. Découvrir tous les *itemsets* fréquents dans D.

2. Générer les règles d'association à partir des *itemsets* fréquents :

   - Pour tous les *itemsets* fréquents X :
     - Pour tous les $A \subset X$: (qui satisfait la contrainte de support) :
       - Générer la règle $A \Rightarrow (X - A)$ (qui satisfait la contrainte de support).
       - Vérifier la confiance de la règle.

Démarche de découverte/extraction des règles d'association

ID	Items
1	A,C,T,W
2	C,D,W
3	A,C,T,W
4	A,C,D,W
5	A,C,D,T,W
6	C,D,T

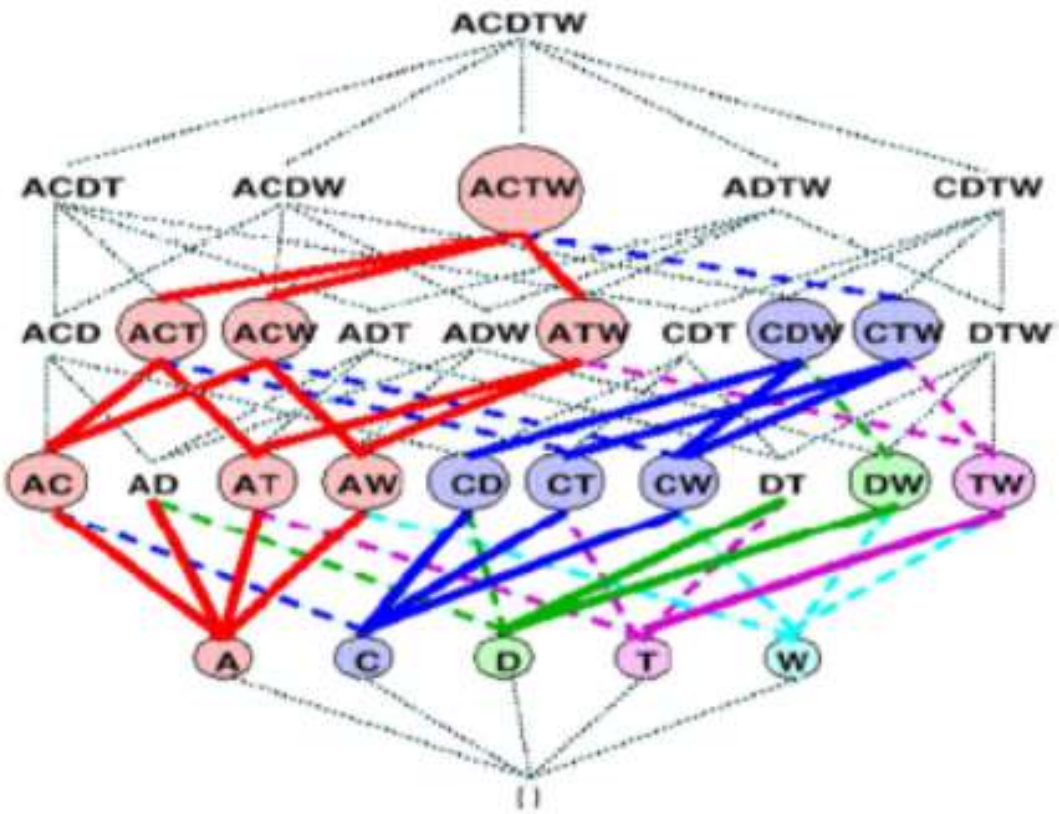

Figure 2 : Treillis d'inclusion des itemsets

Algorithmes d'extraction d'itemset

- Algorithme Naif
- Algorithme Apriori
- Algorithme FP-Growth

Algorithme Naîf

Algorithme d'extraction d'itemset

Entrées :

D : base de transactions

minsup : support minimum

Sortie :

L : ensemble des itemsets fréquents

1. I ← ensemble de tous les items distincts dans D

2. L ← ∅

3. Pour chaque sous-ensemble X de I tel que X ≠ ∅ faire :

```
count ← 0
Pour chaque transaction t dans D faire :
    Si X ⊆ t alors
        count ← count + 1
support(X) ← count / |D|
Si support(X) ≥ minsup alors
    ajouter X à L
```

4. Retourner L

on teste *tous* les sous-ensembles possibles → approche exhaustive.

Algorithme Naîf

Extraction des règles d'association

Entrées :

L : ensemble des itemsets fréquents

D : base de transactions

minconf : confiance minimum

Sortie :

R : ensemble des règles d'association

1. R ← ∅

2. Pour chaque itemset fréquent F dans L tel que |F| ≥ 2 faire :

Pour chaque sous-ensemble non vide A ⊂ F faire :

B ← F − A

support_F ← support(F) // déjà connu depuis Algo 1

support_A ← support(A)

confiance ← support_F / support_A

Si confiance ≥ minconf alors

ajouter la règle A → B à R

3. Retourner R

on teste *tous* les sous-ensembles possibles → approche exhaustive.

Exemple d'execution

Pour chaque sous-ensemble non vide A ⊂ F faire :

$$B \leftarrow F - A$$

F={Pain,Lait,Beurre}

- Les sous-ensembles possibles pour **A** :

A (gauche)	B = F – A (droite)	Règle générée
{Pain}	{Lait, Beurre}	Pain → Lait, Beurre
{Lait}	{Pain, Beurre}	Lait → Pain, Beurre
{Beurre}	{Pain, Lait}	Beurre → Pain, Lait
{Pain, Lait}	{Beurre}	Pain, Lait → Beurre
{Pain, Beurre}	{Lait}	Pain, Beurre → Lait
{Lait, Beurre}	{Pain}	Lait, Beurre → Pain

Coûteux

Algorithme Naîf Coûteux!

- Générer tous les itemsets possibles, puis calculer leur support dans la base de données !

- Problèmes :
  - Comment garder en mémoire un nombre important d'itemsets ?

    100 items => 2^{100} -*1* itemsets possibles !!!!

  - Comment calculer le support d'un nombre important d'itemsets dans une grande base de données (100 million de transactions) ?

Algorithme Apriori

- Apriori :
  - propose par Agrawal et ses co-auteurs en 1994,
  - dans les labos d'IBM pour calculer les ensembles fréquents.

- C'est un algorithme de base :
  - qui permet d'extraire des motifs fréquents,
  - dans une base ayant plusieurs milliers d'attributs et plusieurs millions d'enregistrements.
  - Le nom de l'algorithme provient du fait qu'on utilise des connaissances apriori pour générer les ensembles fréquents.

Algorithme Apriori

- Propriété d'anti-monotonie du support :
  - Tous les sous ensembles d'un itemset fréquent sont fréquents.
  - Si un itemset X n'est pas fréquent alors il n'existe pas d'itemset Y t.q X C Y qui soit fréquent.

Principe de l'Algorithme Apriori

- On construit progressivement les itemsets fréquents : 1-itemsets, 2-itemsets, etc.
- La fonction **Apriori-Gen** génère les candidats de taille k+1 à partir des itemsets fréquents de taille k et applique un **pruning** pour éliminer les candidats impossibles.
- Le support est calculé par un passage sur la base de données.

Algorithme Apriori
Extraction des itemsets fréquents

Entrées :

D : base de transactions

minsup : support minimum

Sortie :

L : ensemble de tous les itemsets fréquents

1. L1 ← { itemsets de taille 1 ayant support ≥ minsup }

2. k ← 2

3. Tant que L(k−1) ≠ ∅ faire :

Ck ← Apriori-Gen(L(k−1)) // génération des nouveaux candidats

Pour chaque transaction t dans D faire :

Ct ← sous-ensembles de Ck contenus dans t

Pour chaque candidat c dans Ct faire :

count(c) ← count(c) + 1

Lk ← { c ∈ Ck tel que support(c) ≥ minsup }

k ← k + 1

4. Retourner L = ∪ Lk

Algorithme Apriori: Apriori-Gen

Entrée :

L(k−1) : itemsets fréquents de taille k−1

Sortie :

Ck : candidats de taille k

1. Ck ← ∅

2. Pour chaque itemset p dans L(k−1)

Pour chaque itemset q dans L(k−1)

Si p et q ont les k−2 premiers items identiques alors

c ← **p** ∪ **q** // jointure

Si tous les sous-ensembles (k−1) de c sont dans L(k−1) alors

ajouter c à Ck // étape d'élagage (pruning)

3. Retourner Ck

Algorithme Apriori: Etape 1

Soit le support min=suppMin=2
Conf_min=60

Dataset

TID	Items/Articles
100	1 3 4
200	2 3 5
300	1 2 3 5
400	2 5
500	1 3 5

Candidate itemset
1-itemset

1-Itemset	Support
{1}	3
{2}	3
{3}	4
{4}	1
{5}	4

Frequent itemset
Frq 1-itemset

1-Itemset	Support
{1}	3
{2}	3
{3}	4
{5}	4

Algorithme Apriori: Etape 2

suppMin=2

Dataset

TID	Items/Articles
100	1 3 4
200	2 3 5
300	1 2 3 5
400	2 5
500	1 3 5

Candidate itemset
2-itemset

2-Itemset	Support
{1,2}	1
{1,3}	3
{1,5}	2
{2,3}	2
{2,5}	3
{3,5}	3

Frequent itemset
Frq 2-itemset

2-Itemset	Support
{1,3}	3
{1,5}	2
{2,3}	2
{2,5}	3
{3,5}	3

Algorithme Apriori: Etape 3

suppMin=2

Dataset

TID	Items/Articles
100	1 3 4
200	2 3 5
300	1 2 3 5
400	2 5
500	1 3 5

Candidate itemset
3-itemset

3-Itemset	Dans Frq 2-Itemset
{1,2,3} {1,2},{1,3},{2,3}	Non
{1,2,5} {1,2},{1,5},{2,5}	Non
{1,3,5} {1,3},{1,5},{3,5}	Oui
{2,3,5} {2,3},{2,5},{3,5}	Oui

Frequent itemset
Frq 3-itemset

1-Itemset	Support
{1,3,5}	2
{2,3,5}	2

Algorithme Apriori: Etape 4

Dataset

TID	Items/Articles
100	1 3 4
200	2 3 5
300	1 2 3 5
400	2 5
500	1 3 5

suppMin=2

Candidate itemset
4-itemset

4-Itemset	support
{1,2,3,5}	1

Frequent itemset
Frq 4-itemset

4-Itemset	Support
vide	

4-Itemset	Dans 3-itemset
{1,2,3,5} {1,2,3},{1,2,5}, {1,3,5}{2,3,5}	

NB: un sous-ensemble d'ensemble fréquents doit être un ensemble fréquent

Algorithme Apriori s'arrête

Dataset

TID	Items/Articles
100	1 3 4
200	2 3 5
300	1 2 3 5
400	2 5
500	1 3 5

suppMin=2

Candidate itemset
3-itemset

3-Itemset	Dans Frq 2-Itemset
{1,2,3} {1,2},{1,3},{2,3}	Non
{1,2,5} {1,2},{1,5},{2,5}	Non
{1,3,5} {1,3},{1,5},{3,5}	Oui
{2,3,5} {2,3},{2,5},{3,5}	Oui

Frequent itemset
Frq 3-itemset

3-Itemset	Support
{1,3,5}	2
{2,3,5}	2

Génération des règles d'association à partir de itmesets fréquent: Etape1

Frequent itemset
Frq 3-itemset

3-Itemset	Support
{1,3,5}	2
{2,3,5}	2

Génération de tous les sous-ensembles non vides pour chaque fréquent k-itemset

- Pour I={1,3,5}, les sous-ensembles non vides sont {1,3}, {1,5}, {3,5}, {1}, {3} et {5}
- Pour I={2,3,5}, les sous-ensembles non vides sont {2,3}, {2,5}, {3,5}, {2}, {3} et {5}

Génération des règles d'association à partir de itemsets fréquent: Etape2

- Pour chaque sous-ensemble non vide **S** de **I**, la règle de sortie

  On note S→ (I-S)

  On lit : l'article **S** recommande l'ensemble **I** moins l'article **S**

  Autrement: Si le client achète l'article **S** alors il va acheter les articles contenant dans l'ensemble **I - S**

TID	Items/Articles
100	1 3 4
200	2 3 5
300	1 2 3 5
400	2 5
500	1 3 5

Bien sûr on doit vérifier la condition suivante:

Si le support_count(I)/support_count(S) >= min_conf

Supposons par exemple que:
Le seuil minimum de la confiance est de 60%

Génération des règles d'association :coupure sur la confiance

- R1: 1&3 →5
  - confiance=sc{1,3,5}/sc{1,3}=2/3=66,66%
  - R1 est sélectionnée
- R2: 1&5 →3
  - confiance=sc{1,5,3}/sc{1,5}=2/2=100%
  - R2 est sélectionnée
- R3: 3&5 →1
  - confiance=sc{3,5,1}/sc{3,5}=2/3=66,66%
  - R3 est sélectionnée
- R4: 1→3&5
  - confiance=sc{1,3,5}/sc{1}=2/3=66,66%
  - R4 est sélectionnée
- R5: 3→1&5
  - confiance=sc{3,1,5}/sc{3}=2/4=50%
  - R5 est rejetée
- R6: 5→1&3
  - confiance=sc{5,1,3}/sc{5}=2/4=50%
  - R6 est rejetée

Quelques applications de l'Algorithme Apriori

- **Analyse de données de capteurs** : Dans le domaine de l'Internet des objets (IoT), l'algorithme Apriori peut être appliqué pour découvrir des associations entre différents capteurs ou dispositifs, aidant à détecter des schémas de comportement ou des anomalies.

- **Marketing et publicité** : utilisé pour découvrir des associations entre les produits, les services ou les pages Web consultées par les utilisateurs, aidant ainsi les spécialistes du marketing à cibler efficacement les clients avec des offres personnalisées.

- **Médecine** : peut être utilisé pour analyser les bases de données de dossiers médicaux électroniques afin d'identifier des combinaisons de symptômes ou de traitements qui sont souvent associés à certaines maladies.
- Etc.